

Traitement automatique du langage

Des fondements linguistiques aux Transformers

Polycopié de synthèse – niveau Master Data Science

2026

Table des matières

Mode d'emploi	7
I Fondements linguistiques et statistiques	8
1 Introduction au NLP	9
1.1 Définition et niveaux d'analyse	9
1.2 Tâches	9
1.3 Difficultés	9
1.4 Démarche expérimentale	9
2 Texte, corpus et prétraitement	10
2.1 Corpus	10
2.2 Unicode et normalisation	10
2.3 Segmentation	10
2.4 Lemmatisation et stemming	10
2.5 Exploration	11
3 Morphologie, syntaxe, sémantique et pragmatique	12
3.1 Morphologie	12
3.2 Syntaxe	12
3.3 Sémantique	12
3.4 Pragmatique et discours	12
4 Représentations discrètes et modèles linéaires	13
4.1 Sac de mots et n-grammes	13
4.2 TF-IDF	13
4.3 Naive Bayes	13

4.4	Régression logistique	13
5	Modèles de séquence probabilistes	15
5.1	Modèles de Markov cachés	15
5.2	CRF linéaire	15
5.3	Évaluation séquentielle	15
II	Représentations et réseaux neuronaux	16
6	Embeddings lexicaux	17
6.1	Hypothèse distributionnelle	17
6.2	Word2Vec, GloVe et FastText	17
6.3	Biais et évaluation	17
7	RNN, LSTM et séquence-à-séquence	18
7.1	RNN	18
7.2	LSTM et GRU	18
7.3	Encodeur-décodeur	18
8	Attention et Transformers	19
8.1	Attention	19
8.2	Bloc Transformer	19
8.3	Encodeurs et décodeurs	19
III	Tâches, évaluation et systèmes	20
9	Classification, sentiments et entités nommées	21
9.1	Formuler une classification	21
9.2	Baselines et modèles	21
9.3	Analyse de sentiments	21
9.4	Déséquilibre et seuils	22
9.5	Étiquetage de séquence	22
9.6	Entités imbriquées et liaison	22
9.7	Analyse d’erreurs	22

10 Analyse syntaxique et extraction d'information	23
10.1 Étiquetage morphosyntaxique	23
10.2 Analyse en constituants	23
10.3 Analyse en dépendances	23
10.4 Extraction de relations	24
10.5 Extraction d'événements	24
10.6 Coréférence	24
10.7 Information ouverte et règles	24
11 Traduction, résumé et questions-réponses	25
11.1 Modélisation séquence-à-séquence	25
11.2 Traduction automatique	25
11.3 Résumé extractif et abstraktif	25
11.4 Questions-réponses extractives	26
11.5 QA ouvert	26
11.6 Décodage et contraintes	26
11.7 Évaluation humaine	26
12 Recherche d'information et sémantique	27
12.1 Modèle booléen et index inversé	27
12.2 BM25	27
12.3 Recherche dense	27
12.4 Recherche approximative et reranking	28
12.5 Recherche hybride	28
12.6 Métriques	28
12.7 Similarité sémantique	28
13 Évaluation, biais et multilinguisme	29
13.1 Concevoir l'évaluation	29
13.2 Métriques et incertitude	29
13.3 Calibration	29
13.4 Biais des données	29
13.5 Équité	30
13.6 Multilinguisme	30

13.7 Transfert et zero-shot interlingue	30
13.8 Reproductibilité	30
14 Mise en production et articulation avec les LLM	31
14.1 Pipeline de production	31
14.2 Choisir l'approche	31
14.3 Latence, débit et coût	31
14.4 Dérive et suivi	31
14.5 Déploiement progressif	32
14.6 Confidentialité et sécurité	32
14.7 Lien avec les LLM	32
IV Pratique et révision	33
15 Travaux pratiques	34
15.1 TP 1 – Classification TF-IDF	34
15.2 TP 2 – Étiquetage et CRF	34
15.3 TP 3 – Embeddings et recherche	34
15.4 TP 4 – Transformer pour le NLP	34
15.5 Rapport attendu	35
16 Exercices	36
17 Corrigés	37
18 Fiches de révision	38
Fiche 1 – Introduction	39
Fiche 2 – Corpus	40
Fiche 3 – Linguistique	41
Fiche 4 – Méthodes linéaires	42
Fiche 5 – Séquences	43
Fiche 6 – Embeddings	44
Fiche 7 – RNN	45
Fiche 8 – Transformer	46
Fiche 9 – Classification et NER	47

Fiche 10 – Syntaxe	48
Fiche 11 – Génération	49
Fiche 12 – Recherche	50
Fiche 13 – Production	51
19 Ateliers guidés d’analyse	52
19.1 Atelier 1 – Concevoir une annotation	52
19.2 Atelier 2 – Diagnostiquer un classifieur	53
19.3 Atelier 3 – Aligner tokens et entités	54
19.4 Atelier 4 – Lire une analyse syntaxique	55
19.5 Atelier 5 – Évaluer une traduction	56
19.6 Atelier 6 – Contrôler la fidélité d’un résumé	57
19.7 Atelier 7 – Construire une recherche hybride	58
19.8 Atelier 8 – Auditer le multilinguisme	59
20 Protocoles de projets complets	60
20.1 Projet A – Routage de tickets	60
20.2 Projet B – Base terminologique	60
20.3 Projet C – Analyse d’avis par aspect	60
20.4 Projet D – Questions-réponses documentaires	61
21 Aide-mémoire mathématique	62
21.1 Probabilités	62
21.2 Classifieurs	62
21.3 Vecteurs et séquences	62
21.4 Métriques	62
22 Compléments de compréhension	64
Complément 1 – Définir le problème	65
Complément 2 – Qualité d’un corpus	66
Complément 3 – Raisonnement linguistique	67
Complément 4 – Pourquoi garder les baselines	68
Complément 5 – Décodage structuré	69
Complément 6 – Géométrie des embeddings	70

Complément 7 – Mémoire et séquences	71
Complément 8 – Interpréter l’attention	72
Complément 9 – Seuils et abstention	73
Complément 10 – Propagation des erreurs	74
Complément 11 – Plusieurs bonnes sorties	75
Complément 12 – Pertinence et utilisateur	76
Complément 13 – Robustesse et équité	77
Complément 14 – Exploiter durablement	78
23 Glossaire et bibliographie	79
23.1 Glossaire	79
23.2 Bibliographie commentée	79
Conclusion	81

Mode d'emploi

Ce cours propose un parcours autonome et progressif en NLP. Il articule linguistique, méthodes symboliques, statistiques et neuronales. Chaque chapitre relie définitions, équations, exemples en français, choix expérimentaux et limites. Le cours LLM peut ensuite approfondir les grands modèles génératifs.

Première partie

Fondements linguistiques et statistiques

Chapitre 1

Introduction au NLP

1.1 Définition et niveaux d'analyse

Le traitement automatique du langage transforme des productions humaines en représentations, prédictions ou textes. Il mobilise phonologie, morphologie, syntaxe, sémantique, pragmatique et discours. Une phrase n'est pas une simple suite de symboles : son interprétation dépend du contexte, du locuteur et du monde.

1.2 Tâches

Classification, étiquetage, entités nommées, analyse syntaxique, recherche, traduction, résumé et questions-réponses correspondent à des sorties différentes. On distingue classification de séquence, prédiction par token, transformation séquence-à-séquence et génération libre.

1.3 Difficultés

Ambiguïté lexicale, références, négation, ironie, variations orthographiques, multilinguisme et évolution des usages rendent le langage difficile. Une performance moyenne peut masquer une faiblesse sur un domaine ou groupe linguistique.

1.4 Démarche expérimentale

Définir l'usage et le coût des erreurs, construire une baseline, séparer entraînement, validation et test, puis analyser les erreurs. Les documents d'une même source doivent rester dans une même partition pour limiter les fuites.

Chapitre 2

Texte, corpus et prétraitement

2.1 Corpus

Un corpus est un ensemble documenté de textes. Provenance, licence, date, langue, genre et population déterminent ce qu'un modèle pourra apprendre. L'échantillonnage est une décision scientifique, pas une formalité.

2.2 Unicode et normalisation

Unicode représente les caractères par points de code ; plusieurs suites peuvent avoir le même rendu. NFC compose les caractères lorsque possible. Normaliser casse, espaces ou ponctuation peut aider une méthode classique mais détruire des indices utiles à une tâche moderne.

2.3 Segmentation

La segmentation en phrases et mots dépend de la langue : un point peut clore une phrase ou une abréviation ; apostrophes et mots composés demandent une convention. Le résultat doit être cohérent avec les annotations et le modèle.

2.4 Lemmatisation et stemming

La lemmatisation ramène une forme à un lemme linguistique ; le stemming applique des règles de troncature. Ces opérations réduisent la sparsité, mais peuvent confondre des formes distinctes. Elles sont souvent inutiles avec des modèles contextuels.

2.5 Exploration

Mesurer volumes, longueurs, vocabulaire, classes, doublons et valeurs manquantes. La fréquence de rang r suit souvent approximativement la loi de Zipf $f(r) \propto r^{-s}$. Une longue traîne motive l'usage des sous-mots.

Chapitre 3

Morphologie, syntaxe, sémantique et pragmatique

3.1 Morphologie

Un morphème est une unité minimale porteuse de fonction ou de sens. Flexion et dérivation expliquent les variantes d'un lemme. Les langues diffèrent fortement dans la manière d'assembler ces unités.

3.2 Syntaxe

La syntaxe décrit l'organisation des constituants ou les dépendances entre mots. Dans une dépendance, une arête relie une tête à un dépendant et porte une relation telle que sujet ou objet.

3.3 Sémantique

La sémantique lexicale étudie polysémie, synonymie, antonymie et relations hiérarchiques. Le principe distributionnel suppose que des mots employés dans des contextes voisins ont souvent des sens proches, sans garantir une équivalence logique.

3.4 Pragmatique et discours

L'intention dépasse le sens littéral. Coréférence, présuppositions et implicatures nécessitent le contexte discursif. Une évaluation purement phrase par phrase ignore ces phénomènes.

Chapitre 4

Représentations discrètes et modèles linéaires

4.1 Sac de mots et n-grammes

Un document devient un vecteur de comptes x_j . Les n-grammes conservent un contexte local au prix d'un vocabulaire plus grand. Les matrices document-terme sont creuses et de haute dimension.

4.2 TF-IDF

Une pondération courante est

$$\text{tfidf}(t, d) = \text{tf}(t, d) \log \frac{N}{\text{df}(t) + 1}.$$

Elle favorise les termes fréquents dans un document mais rares dans la collection.

4.3 Naive Bayes

Le classifieur choisit

$$\hat{c} = \arg \max_c P(c) \prod_t P(t | c)^{n(t,d)}.$$

Le lissage additif évite les probabilités nulles. Malgré l'hypothèse d'indépendance irréaliste, cette baseline est rapide et robuste.

4.4 Régression logistique

Pour deux classes, $P(y = 1 | x) = \sigma(w^\top x + b)$ avec $\sigma(z) = 1/(1 + e^{-z})$. La régularisation $\lambda \|w\|_2^2$ limite la complexité. Les poids restent inspectables, avec prudence lorsque les

variables sont corrélées.

Chapitre 5

Modèles de séquence probabilistes

5.1 Modèles de Markov cachés

Un HMM suppose des états cachés y_t , des transitions $P(y_t \mid y_{t-1})$ et émissions $P(x_t \mid y_t)$:

$$P(x_{1:T}, y_{1:T}) = P(y_1) \prod_{t=2}^T P(y_t \mid y_{t-1}) \prod_{t=1}^T P(x_t \mid y_t).$$

Forward calcule la vraisemblance, Viterbi la meilleure séquence et Baum–Welch estime des paramètres sans états observés.

5.2 CRF linéaire

Un CRF modélise directement $P(y \mid x)$ et combine caractéristiques de l'entrée et transitions d'étiquettes :

$$P(y \mid x) = \frac{\exp s(x, y)}{\sum_{y'} \exp s(x, y')}.$$

Il évite l'hypothèse d'indépendance des émissions du HMM et garantit une séquence cohérente.

5.3 Évaluation séquentielle

Pour les entités, évaluer les segments complets, pas seulement les tokens. Le schéma BIO distingue début, intérieur et extérieur. Rapporter précision, rappel, F1 et erreurs de frontière ou de type.

Deuxième partie

Représentations et réseaux
neuronaux

Chapitre 6

Embeddings lexicaux

6.1 Hypothèse distributionnelle

Une matrice de cooccurrences peut être pondérée par information mutuelle positive :

$$\text{PPMI}(w, c) = \max \left(0, \log \frac{P(w, c)}{P(w)P(c)} \right).$$

Sa factorisation produit des vecteurs denses.

6.2 Word2Vec, GloVe et FastText

Skip-gram prédit le contexte ; CBOW prédit le mot central. GloVe ajuste les produits scalaires aux rapports de cooccurrence. FastText représente un mot par des n-grammes de caractères et gère mieux variantes et mots rares.

6.3 Biais et évaluation

Analogies et similarités intrinsèques ne garantissent pas la performance applicative. Les embeddings reflètent stéréotypes et déséquilibres du corpus. L'évaluation extrinsèque sur la tâche finale reste indispensable.

Chapitre 7

RNN, LSTM et séquence-à-séquence

7.1 RNN

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b).$$

Le partage des poids traite des longueurs variables, mais la rétropropagation dans le temps multiplie des Jacobiennes et provoque gradients évanescents ou explosifs.

7.2 LSTM et GRU

Les portes contrôlent oubli, écriture et lecture d'un état mémoire. Elles facilitent les dépendances longues sans supprimer le calcul séquentiel. Le clipping borne la norme du gradient.

7.3 Encodeur-décodeur

Un encodeur résume l'entrée et un décodeur produit la sortie. Le teacher forcing entraîne avec le token réel précédent, tandis que l'inférence utilise les propres prédictions du modèle, créant un décalage d'exposition.

Chapitre 8

Attention et Transformers

8.1 Attention

$$\text{Att}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} + M \right) V.$$

Le masque M encode positions interdites. Plusieurs têtes apprennent des projections distinctes, concaténées puis reprojétées.

8.2 Bloc Transformer

Attention, connexion résiduelle, normalisation et réseau feed-forward forment un bloc. Les positions sont injectées par embeddings appris ou fonctions relatives. L'attention dense coûte $O(T^2)$ en longueur.

8.3 Encodeurs et décodeurs

Un encodeur bidirectionnel convient à compréhension et étiquetage ; un décodeur causal à génération ; l'encodeur-décodeur à traduction ou résumé conditionnel. Le choix dépend de la structure de sortie.

Troisième partie

Tâches, évaluation et systèmes

Chapitre 9

Classification, sentiments et entités nommées

9.1 Formuler une classification

Une classification associe un texte x à une étiquette y . Elle peut être binaire, multiclasse ou multilabel. Avant le modèle, il faut définir l'unité à classer, les catégories, les cas ambigus et la décision métier. Une taxonomie non exclusive ne doit pas être forcée en multiclasse.

Pour K classes exclusives, les logits z_k deviennent

$$P(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad \mathcal{L} = - \sum_{k=1}^K y_k \log P(y = k \mid x).$$

En multilabel, chaque classe utilise plutôt une sigmoïde et une entropie croisée binaire.

9.2 Baselines et modèles

Une baseline majoritaire révèle le déséquilibre mais n'exploite pas le texte. TF-IDF avec régression logistique ou SVM linéaire constitue une référence forte, rapide et interprétable. Un encodeur neuronal produit une représentation contextuelle, souvent celle d'un token spécial ou une moyenne, puis une tête de classification.

9.3 Analyse de sentiments

Le sentiment peut viser document, phrase ou aspect. “La caméra est excellente mais la batterie médiocre” ne possède pas une polarité unique utile. Négation, intensité, ironie et domaine changent l'interprétation. Les classes doivent parfois inclure neutre, mixte ou non applicable.

9.4 Déséquilibre et seuils

Pondérer la loss, rééchantillonner ou ajuster le seuil peut améliorer une classe rare. Le seuil se choisit sur validation selon le coût des faux positifs et faux négatifs. Pour une classe positive,

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = 2 \frac{PR}{P + R}.$$

En multiclass, macro-F1 traite chaque classe également ; micro-F1 agrège les décisions et favorise les classes fréquentes.

9.5 Étiquetage de séquence

La reconnaissance d'entités nommées attribue une étiquette à chaque token. Le schéma BIO encode début, intérieur et extérieur : B-PER I-PER O B-LOC. Une entité n'est correcte que si type et frontières correspondent. La tokenisation en sous-mots exige d'aligner les annotations originales aux tokens du modèle.

9.6 Entités imbriquées et liaison

Des entités peuvent se chevaucher, ce qu'un BIO simple représente mal. La liaison d'entités associe ensuite une mention à un identifiant dans une base de connaissances ; elle doit gérer homonymie et entité absente. Détection de mention et désambiguïsation s'évaluent séparément.

9.7 Analyse d'erreurs

Construire une matrice de confusion, puis inspecter longueur, négation, mots rares, domaine, langue et qualité d'annotation. Une divergence entre annotateurs peut signaler un problème de consigne plutôt qu'un défaut du modèle.

Chapitre 10

Analyse syntaxique et extraction d'information

10.1 Étiquetage morphosyntaxique

Le POS tagging attribue une catégorie grammaticale contextualisée. Dans “ils président la séance” et “le président”, la forme identique reçoit deux catégories. Les jeux d'étiquettes universels facilitent la comparaison entre langues mais perdent parfois des distinctions locales.

10.2 Analyse en constituants

Une grammaire hors contexte utilise des règles telles que $S \rightarrow NP VP$. Un parseur construit un arbre hiérarchique. Les ambiguïtés d'attachement produisent plusieurs arbres possibles ; un modèle probabiliste préfère celui de probabilité maximale.

10.3 Analyse en dépendances

Chaque mot, sauf la racine, dépend d'une tête. Un arbre dirigé capture relations sujet, objet ou modifieur. Les approches par transitions construisent l'arbre par actions ; les approches par graphe cherchent un arbre de score maximal.

L'UAS mesure la proportion de têtes correctes ; le LAS exige tête et relation correctes :

$$UAS = \frac{\text{\#têtes correctes}}{N}, \quad LAS = \frac{\text{\#têtes et labels corrects}}{N}.$$

On exclut ou non la ponctuation selon une convention à préciser.

10.4 Extraction de relations

À partir d’entités détectées, on prédit une relation orientée, par exemple `travaille-pour` entre une personne et une organisation. Les candidats négatifs sont nombreux ; l’échantillonnage influence fortement l’apprentissage. Une approche jointe peut réduire la propagation d’erreurs mais complexifie le modèle.

10.5 Extraction d’événements

Un événement comprend déclencheur et arguments typés. “Paul a rejoint X à Paris” peut donner un événement d’embauche avec personne, organisation et lieu. Évaluer séparément déclencheurs, arguments, rôles et correspondance complète.

10.6 Coréférence

La résolution de coréférence regroupe les mentions désignant une même entité. Pronoms, descriptions et ellipses requièrent le discours. Les métriques classiques évaluent liens ou clusters et peuvent réagir différemment aux erreurs ; il est courant d’en rapporter une moyenne.

10.7 Information ouverte et règles

Les règles et motifs restent précieux lorsque la structure est stable et l’exigence de précision forte. L’extraction ouverte cherche des triplets sans ontologie fermée, mais produit synonymes et relations difficiles à normaliser. Les systèmes hybrides combinent modèles, dictionnaires, contraintes et validation.

Réflexe. Pour toute extraction, conserver le passage source et les offsets.
Une valeur sans provenance est difficile à vérifier, corriger ou auditer.

Chapitre 11

Traduction, résumé et questions-réponses

11.1 Modélisation séquence-à-séquence

Pour une entrée x et une sortie $y_{1:T}$,

$$P(y \mid x) = \prod_{t=1}^T P(y_t \mid y_{<t}, x).$$

L'entraînement minimise la cross-entropie avec la référence. Plusieurs sorties étant acceptables, la vraisemblance d'une seule référence ne décrit pas toute la qualité.

11.2 Traduction automatique

Une traduction doit préserver sens, registre, terminologie et contraintes de forme. Les noms propres, nombres et phénomènes rares méritent des tests dédiés. Les modèles multilingues permettent transfert entre langues, mais les langues peu représentées restent souvent moins performantes.

BLEU calcule une précision de n-grammes modifiée et une pénalité de brièveté :

$$BLEU = BP \exp \left(\sum_{n=1}^N w_n \log p_n \right).$$

Il est utile à l'échelle d'un corpus, moins pour juger une phrase isolée. Une évaluation humaine examine adéquation et fluidité.

11.3 Résumé extractif et abstraktif

L'extractif sélectionne des passages ; l'abstraktif reformule. Le résumé doit équilibrer couverture, concision, cohérence et fidélité. Les hallucinations sont particulièrement graves lorsque le lecteur suppose que toute information vient du document.

ROUGE- N mesure principalement le rappel des n -grammes de référence. ROUGE-L utilise une plus longue sous-séquence commune. Ces métriques récompensent le recouvrement lexical, mais ni la factualité ni toutes les bonnes paraphrases.

11.4 Questions-réponses extractives

Dans le QA extractif, le modèle prédit les positions de début s et fin e d'une réponse dans le passage. On peut maximiser $P(s | x)P(e | x)$ sous $s \leq e$. Exact Match exige la même chaîne normalisée ; token-F1 tolère un chevauchement partiel.

11.5 QA ouvert

Un système ouvert récupère d'abord des documents puis extrait ou génère. On distingue échec de récupération, preuve insuffisante et génération incorrecte. Les questions sans réponse imposent une capacité d'abstention.

11.6 Décodage et contraintes

Greedy choisit le token maximal ; beam search conserve plusieurs hypothèses ; le sampling augmente la diversité. En traduction factuelle, un décodage contrôlé est souvent préférable. Des contraintes lexicales peuvent imposer une terminologie, avec risque de dégrader la grammaticalité.

11.7 Évaluation humaine

Définir des critères séparés et des niveaux illustrés. Masquer l'identité des systèmes, randomiser l'ordre, mesurer l'accord et examiner les désaccords. Une préférence globale sans justification diagnostique peu les défauts.

Chapitre 12

Recherche d'information et sémantique

12.1 Modèle booléen et index inversé

Un index inversé associe chaque terme à la liste des documents qui le contiennent. Les requêtes booléennes offrent un contrôle précis mais classent mal les résultats et gèrent peu la synonymie.

12.2 BM25

BM25 pondère fréquence du terme, rareté et longueur du document :

$$\text{BM25}(q, d) = \sum_{t \in q} \text{IDF}(t) \frac{tf(t, d)(k_1 + 1)}{tf(t, d) + k_1(1 - b + b|d|/avgdl)}.$$

Cette baseline lexicale est forte, explicable et efficace, notamment pour identifiants ou mots rares.

12.3 Recherche dense

Un bi-encodeur projette requête et document séparément. Le score est souvent $q^\top d$ ou le cosinus. L'entraînement contrastif rapproche les paires positives et éloigne les négatifs :

$$\mathcal{L} = -\log \frac{e^{s(q, d^+)/\tau}}{e^{s(q, d^+)/\tau} + \sum_j e^{s(q, d_j^-)/\tau}}.$$

Les négatifs difficiles sont essentiels mais un faux négatif nuit au signal.

12.4 Recherche approximative et reranking

Pour des millions de vecteurs, ANN échange un peu de rappel contre vitesse. Un cross-encodeur lit requête et document ensemble et reranke un petit ensemble ; il est plus précis mais trop coûteux pour toute la collection.

12.5 Recherche hybride

Lexical et dense sont complémentaires. Reciprocal Rank Fusion combine des rangs :

$$RRF(d) = \sum_m \frac{1}{k + r_m(d)}.$$

On règle la fusion sur validation, sans supposer qu'un score brut BM25 est comparable à un cosinus.

12.6 Métriques

Recall@ k vérifie si les documents pertinents sont présents. MRR utilise le rang du premier résultat pertinent :

$$MRR = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i}.$$

La nDCG valorise plusieurs niveaux de pertinence et les premiers rangs. Les jugements incomplets rendent certains “faux positifs” simplement non annotés.

12.7 Similarité sémantique

La similarité textuelle peut être régression ou classement ordinal. Paraphrase, entailment et proximité thématique ne sont pas identiques. Deux phrases proches peuvent se contredire par une négation ; la distance vectorielle seule ne remplace pas une relation logique.

Chapitre 13

Évaluation, biais et multilinguisme

13.1 Concevoir l'évaluation

Une évaluation relie population d'entrées, sortie attendue, métrique et décision. Construire un test représentatif, figé et versionné ; réserver un jeu de non-régression aux incidents. Rapporter résultats par classe, langue, longueur, domaine et difficulté.

13.2 Métriques et incertitude

Accuracy convient aux classes équilibrées et coûts symétriques. Macro-F1 protège la visibilité des classes rares. Une métrique doit être accompagnée d'un intervalle de confiance, par exemple obtenu par bootstrap. Pour comparer deux systèmes, rééchantillonner les différences exemple par exemple préserve leur appariement.

13.3 Calibration

Une probabilité de 0,8 est calibrée si environ 80% des prédictions semblables sont correctes. Le score de Brier binaire est

$$BS = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2.$$

Calibration et discrimination sont distinctes. Le seuil final dépend du coût des erreurs et d'une éventuelle option de rejet.

13.4 Biais des données

Les annotations reflètent définitions, annotateurs et contexte social. Les données web ne représentent pas uniformément les langues ni populations. Documenter exclusions, désaccords, données synthétiques et transformations permet d'interpréter les limites.

13.5 Équité

Comparer taux d'erreur ou opportunité entre groupes lorsque l'attribut est pertinent et légalement utilisable. Plusieurs critères d'équité peuvent être incompatibles si les taux de base diffèrent. Le choix est normatif et métier, pas uniquement mathématique.

13.6 Multilinguisme

Les langues varient par morphologie, écriture, ordre des mots et ressources. Traduire un benchmark ne garantit pas l'équivalence culturelle ni la même difficulté. Il faut des locuteurs compétents, des exemples natifs et des analyses par variété linguistique.

13.7 Transfert et zero-shot interlingue

Un modèle multilingue peut apprendre un espace partagé et transférer d'une langue riche vers une langue peu annotée. Le transfert dépend de la proximité, du tokenizer et de la représentation au pré-entraînement. Quelques annotations locales restent précieuses pour mesurer et corriger les écarts.

13.8 Reproductibilité

Conserver versions des données, code, dépendances, graines, modèle et paramètres. Rapporter moyenne et dispersion de plusieurs entraînements si la variance est notable. Une amélioration inférieure à la variabilité expérimentale n'est pas une conclusion solide.

Attention. Une métrique publique n'est pas le problème réel. Elle devient utile seulement si ses exemples, erreurs et pondérations ressemblent à la décision que le système doit soutenir.

Chapitre 14

Mise en production et articulation avec les LLM

14.1 Pipeline de production

Un système NLP comprend ingestion, validation, prétraitement, modèle, post-traitement, API et observabilité. Les mêmes transformations doivent être appliquées à l'entraînement et à l'inférence. Un schéma d'entrée versionné empêche les changements silencieux.

14.2 Choisir l'approche

Commencer par règles ou TF-IDF lorsque données et latence sont limitées. Employer un encodeur pré-entraîné pour la compréhension contextuelle, un modèle séquence-à-séquence pour la transformation, un LLM pour les tâches ouvertes. La complexité n'est justifiée que par un gain mesuré.

14.3 Latence, débit et coût

Suivre médiane et percentiles, taille des lots, mémoire et coût par prédiction correcte. Batching, quantification et distillation peuvent accélérer l'inférence. Le cache doit intégrer les versions du modèle et du prétraitement.

14.4 Dérive et suivi

La dérive de données modifie $P(X)$; la dérive de concept modifie $P(Y | X)$. Surveiller longueurs, langues, vocabulaire, confiance, erreurs et retours. Seules des étiquettes retardées permettent d'observer directement la qualité réelle.

14.5 Déploiement progressif

Tester hors ligne, en shadow mode, puis sur une faible proportion du trafic. Comparer à la référence et prévoir rollback. Versionner données, modèle, seuils, taxonomie et dépendances comme un ensemble.

14.6 Confidentialité et sécurité

Minimiser les textes conservés, masquer les données inutiles, contrôler accès et rétention. Les documents externes sont des entrées hostiles possibles. Les décisions sensibles exigent validation métier et voie de recours humaine.

14.7 Lien avec les LLM

Le NLP fournit tâches, données, métriques et concepts linguistiques ; les LLM offrent une interface générale. Un LLM ne rend pas obsolètes corpus annotés, recherche, extraction déterministe ni analyse d'erreurs. Il les combine dans des systèmes plus flexibles.

Quatrième partie

Pratique et révision

Chapitre 15

Travaux pratiques

15.1 TP 1 – Classification TF–IDF

Construire un classifieur de sentiments. Explorer classes, longueurs et doublons ; séparer les données par source ; entraîner baseline majoritaire puis TF–IDF avec régression logistique. Régler le seuil sur validation et présenter matrice de confusion, macro-F1 et dix erreurs commentées. Comparer unigrammes, bigrammes et n-grammes de caractères.

15.2 TP 2 – Étiquetage et CRF

À partir d’un corpus BIO, vérifier les transitions, extraire des caractéristiques locales et entraîner un CRF. Comparer à des prédictions indépendantes par token. Évaluer les entités complètes, puis classer les erreurs de frontière, de type et d’entités inconnues.

15.3 TP 3 – Embeddings et recherche

Créer une collection et des requêtes avec jugements de pertinence. Comparer TF–IDF/BM25, embeddings denses et fusion RRF. Mesurer Recall@5, MRR et latence. Étudier les échecs lexicaux et sémantiques.

15.4 TP 4 – Transformer pour le NLP

Adapter un encodeur à la classification ou au NER. Documenter tokenizer, alignement, hyperparamètres et courbes. Comparer à la baseline classique selon qualité, coût et robustesse. Tester textes longs, fautes, négations et cas hors domaine.

15.5 Rapport attendu

Présenter question, données et droits, protocole, baseline, métriques, résultats avec incertitude, analyse d'erreurs, limites et expérience suivante. Une capture de score sans protocole n'est pas un résultat reproductible.

Chapitre 16

Exercices

1. Donner deux lectures de “J’ai vu l’homme avec les jumelles”.
2. Expliquer pourquoi la mise en minuscules peut nuire au NER.
3. Distinguer lemme, morphème et token.
4. Calculer IDF pour un terme présent dans 10 documents sur 1000.
5. Pour $TP = 40$, $FP = 10$, $FN = 20$, calculer précision, rappel et F1.
6. Comparer macro-F1 et micro-F1.
7. Factoriser la probabilité jointe d’un HMM.
8. Pourquoi Viterbi diffère-t-il du meilleur label indépendant par position ?
9. Encoder “Marie Curie travaille à Paris” en BIO.
10. Distinguer UAS et LAS.
11. Calculer le cosinus entre $(1, 1)$ et $(2, 0)$.
12. Expliquer l’intérêt de FastText pour un mot rare.
13. Décrire le décalage d’exposition d’un décodeur seq2seq.
14. Donner la dimension de $QK^\top$ pour 256 tokens.
15. Pourquoi BLEU ne suffit-il pas à évaluer une traduction ?
16. Distinguer résumé extractif et abstraktif.
17. Interpréter Recall@10 élevé et MRR faible.
18. Proposer une évaluation multilingue avec exemples natifs.

Chapitre 17

Corrigés

Les jumelles peuvent être l'instrument ou appartenir à l'homme. La casse distingue parfois noms propres et communs. Le lemme est une forme canonique, le morphème une unité de fonction ou sens, le token une unité de traitement.

$IDF = \log(1000/11) \simeq 4,51$. Avec les valeurs données, $P = 0,8$, $R = 2/3$ et $F_1 \simeq 0,727$. Macro moyenne les classes ; micro agrège les décisions.

Pour un HMM, $P(x, y) = P(y_1) \prod_{t=2}^T P(y_t \mid y_{t-1}) \prod_t P(x_t \mid y_t)$. Viterbi optimise la séquence entière. Les tags sont B-PER I-PER O O B-LOC. UAS exige la bonne tête ; LAS exige aussi la relation.

Le cosinus vaut $1/\sqrt{2}$. FastText compose un mot avec ses sous-chaînes. En teacher forcing le décodeur voit les tokens vrais, contrairement à l'inférence. La matrice mesure 256×256 par tête.

BLEU ignore une partie du sens, de la factualité et des paraphrases. L'extractif copie ; l'abstraktif reformule. Recall élevé et MRR faible indique des documents pertinents présents mais mal classés. Un test multilingue doit contenir des exemples natifs annotés par des locuteurs compétents.

Chapitre 18

Fiches de révision

Fiche 1 – Introduction

Idée centrale. Le NLP transforme le langage selon une tâche définie.

À maîtriser. Niveaux linguistiques, tâches et protocole.

Piège. Réduire le langage à des mots isolés.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 2 – Corpus

Idée centrale. Le corpus borne ce qu'apprend et mesure le système.

À maîtriser. Unicode, segmentation, normalisation, Zipf et fuites.

Piège. Nettoyer sans inspecter les pertes.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 3 – Linguistique

Idée centrale. Les niveaux linguistiques sont complémentaires.

À maîtriser. Morphèmes, dépendances, polysémie et pragmatique.

Piège. Confondre proximité et identité de sens.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 4 – Méthodes linéaires

Idée centrale. Les vecteurs creux restent des baselines fortes.

À maîtriser. TF-IDF, Naive Bayes, logistique et régularisation.

Piège. Sauter la baseline.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 5 – Séquences

Idée centrale. HMM et CRF modélisent des étiquettes cohérentes.

À maîtriser. Transitions, Viterbi, partition, BIO et segment-F1.

Piège. Évaluer seulement par token.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 6 – Embeddings

Idée centrale. Les vecteurs apprennent des régularités distributionnelles.

À maîtriser. PPMI, Word2Vec, GloVe, FastText et cosinus.

Piège. Prendre une analogie pour une preuve.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 7 – RNN

Idée centrale. La récurrence partage un état dans le temps.

À maîtriser. BPTT, LSTM, clipping, seq2seq et teacher forcing.

Piège. Supposer une mémoire illimitée.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 8 – Transformer

Idée centrale. L'attention relie directement les positions.

À maîtriser. Q/K/V, masque, têtes, résidus et complexité.

Piège. Oublier les dimensions.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 9 – Classification et NER

Idée centrale. Labels et seuils déterminent la décision.

À maîtriser. Softmax, macro/micro, BIO et frontières.

Piège. Confondre multilabel et multiclasse.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 10 – Syntaxe

Idée centrale. Les structures enrichissent les tokens.

À maîtriser. POS, constituants, dépendances, relations et événements.

Piège. Perdre la provenance.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 11 – Génération

Idée centrale. Les sorties sont conditionnées par une entrée.

À maîtriser. BLEU, ROUGE, EM/F1, fidélité et décodage.

Piège. Confondre recouvrement et qualité.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 12 – Recherche

Idée centrale. Lexical et dense sont complémentaires.

À maîtriser. BM25, contrastif, ANN, RRF, Recall, MRR et nDCG.

Piège. Comparer des scores incompatibles.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Fiche 13 – Production

Idée centrale. Qualité, disparités, dérive et coûts doivent être suivis.

À maîtriser. Calibration, bootstrap, canary, versionnement et sécurité.

Piège. Optimiser une moyenne hors métier.

Auto-test.

1. Définir les notions sans notes.
2. Écrire les équations et préciser les variables.
3. Donner un exemple et un contre-exemple.
4. Choisir une métrique et analyser un échec.

Chapitre 19

Ateliers guidés d'analyse

19.1 Atelier 1 – Concevoir une annotation

On souhaite repérer les demandes de résiliation dans des courriels. Commencer par écrire l'unité : message complet, phrase ou tour de dialogue. Définir positifs explicites, intentions implicites, demandes hypothétiques, citations et messages transférés. Créer une catégorie "incertain" pendant la phase pilote plutôt que forcer artificiellement l'accord.

Deux annotateurs traitent le même échantillon. Pour deux catégories, l'accord de Cohen est

$$\kappa = \frac{p_o - p_e}{1 - p_e},$$

où p_o est l'accord observé et p_e l'accord attendu par les marginales. Un faible κ peut venir d'une consigne ambiguë, de cas réellement subjectifs ou d'un fort déséquilibre. Examiner les désaccords avant de recruter davantage d'annotateurs.

Après le pilote, réviser le guide avec exemples et contre-exemples, puis réannoter une partie. Documenter l'adjudication : qui tranche, avec quelle information et selon quelle règle ? Le label final ne doit pas effacer l'incertitude initiale.

Travail demandé. Écrire dix règles, vingt cas limites et une fiche de décision d'une page. Calculer accord global et par catégorie. Proposer la taille du double échantillonnage pour surveiller la qualité durant la campagne.

19.2 Atelier 2 – Diagnostiquer un classifieur

Un modèle d'intention obtient 92% d'accuracy mais confond “modifier une adresse” et “modifier une livraison”. La première étape est de comparer à la fréquence de la classe majoritaire, puis de lire la matrice de confusion normalisée par ligne et par colonne.

Construire des tranches : longueur, présence d'un numéro, canal, langue, nouveau client et période. Mesurer macro-F1 et rappel des classes critiques. Pour chaque confusion fréquente, inspecter vrais positifs, faux positifs et faux négatifs. Chercher labels inconsistants, exemples presque identiques entre partitions et indices accidentels.

Une courbe précision-rappel permet de déplacer le seuil pour une classe multilabel. Si le coût d'un faux négatif vaut C_{FN} et celui d'un faux positif C_{FP} , comparer

$$C(\tau) = C_{FN}FN(\tau) + C_{FP}FP(\tau).$$

Le minimum empirique sur validation suggère un seuil, à confirmer sous les contraintes de capacité humaine.

Travail demandé. Produire une taxonomie de dix erreurs, proposer trois corrections ciblées et prévoir une expérience qui permet de distinguer leurs effets. Ne changer qu'un facteur à la fois.

19.3 Atelier 3 – Aligner tokens et entités

Les annotations originales utilisent des offsets de caractères, tandis qu'un Transformer produit des sous-mots. Conserver la correspondance entre chaque sous-token et la chaîne originale. Le premier sous-token reçoit le label B ou I attendu ; les suivants peuvent recevoir I ou être masqués dans la loss selon le protocole.

Les cas difficiles incluent apostrophes, tirets, emojis, normalisation Unicode et espaces multiples. Toute transformation avant alignement peut déplacer les offsets. Un test unitaire doit reconstruire le fragment à partir des bornes et vérifier qu'il correspond à la mention annotée.

Comparer évaluation token et segment. Le modèle peut reconnaître tous les mots d'une organisation sauf le dernier : son accuracy token reste élevée, mais l'entité complète est fausse. Présenter erreurs de frontière, de type, entité manquée et entité parasite.

Travail demandé. Inventer quinze phrases françaises couvrant personnes composées, sigles, lieux avec article et entités imbriquées. Définir la convention avant d'annoter.

19.4 Atelier 4 – Lire une analyse syntaxique

Comparer deux analyses de “Elle observe le satellite avec un télescope”. Dans l’une, le groupe prépositionnel modifie le verbe ; dans l’autre, il modifie le satellite. Les deux arbres sont grammaticalement plausibles mais expriment des interprétations différentes.

Identifier racine, sujet, objet et modifieurs. Puis tester coordination, relatives et ponctuation. UAS localise les mauvaises têtes, LAS les relations mal nommées. Une erreur proche de la racine peut affecter plusieurs traitements en aval même si un seul arc est compté faux.

La syntaxe peut fournir des caractéristiques à une extraction de relation, mais un parseur hors domaine propage ses erreurs. Comparer une solution utilisant l’arbre à une baseline ne l’utilisant pas. Le gain doit être mesuré sur les structures où la syntaxe est censée aider.

Travail demandé. Dessiner des arbres de dépendances pour cinq ambiguïtés et expliquer quelles informations contextuelles permettraient de choisir.

19.5 Atelier 5 – Évaluer une traduction

Constituer un échantillon stratifié par longueur, domaine, nombres, négation, terminologie et expressions idiomatiques. Une seule référence ne couvre pas toutes les traductions valides. BLEU sert au suivi global, tandis qu’une grille humaine sépare conservation du sens, fluidité, terminologie et erreurs critiques.

Les nombres, unités, dates et noms propres peuvent être vérifiés automatiquement. Pour la terminologie, construire une liste bilingue avec formes acceptées et contexte. Une traduction fluide qui inverse une négation doit recevoir une pénalité plus forte qu’une maladresse stylistique.

Effectuer une comparaison aveugle par paires, en alternant l’ordre des systèmes. Rapporter taux de victoire, égalités, accord inter-annotateurs et exemples. Une différence moyenne faible peut cacher une nette supériorité sur un domaine précis.

Travail demandé. Créer une grille à quatre niveaux et l’appliquer à vingt segments. Expliquer les cinq désaccords les plus instructifs.

19.6 Atelier 6 – Contrôler la fidélité d’un résumé

Décomposer chaque résumé en affirmations atomiques. Pour chacune, rechercher un passage source qui la soutient, la contredit ou ne permet pas de conclure. Marquer aussi les informations importantes absentes.

On peut définir une fidélité $F = S/(S+U+C)$, où S compte les affirmations soutenues, U les non étayées et C les contradictoires. Cette formule simple doit être complétée par couverture et lisibilité : supprimer presque toutes les affirmations améliorerait artificiellement F .

Comparer une méthode extractive et une méthode abstractive sur des documents longs. L’extractive est généralement fidèle mais peut manquer de cohérence ; l’abstractive synthétise mieux mais risque d’inventer des liens. Examiner notamment attribution des propos, causalité et temporalité.

Travail demandé. Annoter dix résumés, rédiger une justification avec offsets de preuve et proposer une politique d’abstention lorsque les sources se contredisent.

19.7 Atelier 7 – Construire une recherche hybride

Indexer titres, corps et métadonnées. BM25 favorise les correspondances lexicales ; un bi-encodeur retrouve des paraphrases. Évaluer séparément requêtes exactes, conceptuelles, avec faute et avec identifiant. Une fusion doit améliorer des catégories complémentaires plutôt qu’une moyenne par hasard.

Pour chaque requête, conserver plusieurs documents pertinents et leur niveau. Calculer $\text{Recall}@k$, MRR et nDCG. Inspecter aussi les requêtes sans jugement complet : un document pertinent non annoté ne doit pas devenir automatiquement un faux positif.

Ajouter un reranker aux vingt premiers candidats. Mesurer le gain et le coût. Une amélioration de rang inutile à l’utilisateur final ne compense pas nécessairement la latence. Tester filtres d’accès avant et après la recherche ; seul le filtrage empêchant toute exposition non autorisée est acceptable.

Travail demandé. Produire un tableau d’ablation : lexical seul, dense seul, hybride, hybride plus reranker. Commenter qualité, latence et mémoire.

19.8 Atelier 8 – Auditer le multilinguisme

Échantillonner des textes natifs, pas seulement traduits, dans chaque langue. Documenter variété, région, registre, système d’écriture et domaine. La notion de “langue” masque souvent plusieurs usages dont les performances diffèrent.

Comparer tokenizer : nombre de tokens par mot, proportion de fragments rares et troncature. Un modèle peut sembler plus lent dans une langue simplement parce que sa segmentation est moins efficace. Les erreurs morphologiques et les mélanges de langues méritent des catégories dédiées.

Évaluer zero-shot, transfert et petit fine-tuning local. Une moyenne macro par langue donne le même poids à chacune ; une moyenne pondérée reflète le trafic. Présenter les deux lorsqu’elles répondent à des questions différentes.

Travail demandé. Rédiger une fiche de données multilingue, proposer des tests d’équité linguistique et indiquer les limites qu’un échantillon réduit ne permet pas de conclure.

Chapitre 20

Protocoles de projets complets

20.1 Projet A – Routage de tickets

Question. Peut-on réduire le délai de traitement sans augmenter les erreurs graves ? Définir intentions, urgence et équipe cible. Constituer les partitions par client ou fil de conversation. Comparer règles, TF-IDF et encodeur contextualisé.

Évaluation. Macro-F1 pour les intentions, rappel pour urgences, taux de routage automatique, corrections humaines et temps économisé. Tester nouveaux produits, messages très courts et langues minoritaires. Calibrer une abstention envoyant les cas incertains à un opérateur.

Production. Journaliser version et décision, jamais plus de texte personnel que nécessaire. Déployer en suggestion avant automatisation. Une boucle mensuelle réexamine taxonomie, dérive et classes émergentes.

20.2 Projet B – Base terminologique

Extraire termes spécialisés, variantes et contextes depuis des documents techniques. Combiner motifs linguistiques, scores statistiques et validation experte. Lier chaque entrée à ses occurrences et à une version documentaire.

Évaluer précision des candidats en tête de liste, couverture des termes connus et temps de validation. Les acronymes ambigus sont désambiguïsés par domaine. La base sert ensuite à la recherche et au contrôle de traduction.

20.3 Projet C – Analyse d’avis par aspect

Détecter aspects, expressions d’opinion et polarité. Une phrase peut contenir plusieurs couples aspect-sentiment. Comparer pipeline NER puis classification et modèle joint. Mesurer extraction exacte et polarité conditionnelle à l’aspect correct.

Les avis synthétiques ou incités, le sarcasme et la dérive des produits limitent l'interprétation. Agréger seulement après avoir estimé la couverture et l'incertitude. Les tableaux de bord doivent permettre de revenir aux exemples sources.

20.4 Projet D – Questions-réponses documentaires

Construire des questions répondables et non répondables, avec documents pertinents annotés. Mesurer retrieval avant QA. Pour une réponse extractive, conserver bornes et document ; pour une réponse générée, vérifier chaque affirmation.

Ajouter des tests de documents contradictoires, versions obsolètes et droits d'accès. Le système doit citer, dater et s'abstenir. La réussite combine exactitude, provenance, latence et absence de fuite.

Chapitre 21

Aide-mémoire mathématique

21.1 Probabilités

$$P(x_{1:T}) = \prod_{t=1}^T P(x_t \mid x_{<t}), \quad P(y \mid x) = \frac{P(x \mid y)P(y)}{P(x)}.$$
$$H(p, q) = - \sum_x p(x) \log q(x), \quad D_{KL}(p \parallel q) = \sum_x p(x) \log \frac{p(x)}{q(x)}.$$

21.2 Classifieurs

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{softmax}(z)_k = \frac{e^{z_k}}{\sum_j e^{z_j}}.$$

La cross-entropie multiclassées est $-\sum_k y_k \log \hat{p}_k$. Une régularisation ajoute une pénalité sur les poids.

21.3 Vecteurs et séquences

$$\cos(u, v) = \frac{u^\top v}{\|u\| \|v\|}, \quad h_t = f(W_x x_t + W_h h_{t-1} + b).$$
$$\text{Att}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} + M \right) V.$$

21.4 Métriques

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}.$$

Pour la recherche, $MRR = N^{-1} \sum_i 1/r_i$. Toujours préciser unité, moyenne macro ou micro, seuil et intervalle d'incertitude.

Chapitre 22

Compléments de compréhension

Complément 1 – Définir le problème

Une demande vague comme “comprendre les avis” peut désigner polarité globale, aspects, causes ou résumé. Écrire d’abord la décision en aval, l’unité, la sortie et le coût des erreurs. Construire ensuite quelques exemples contradictoires. Si deux sorties différentes conviennent à la même entrée, la consigne ou la représentation doit être affinée.

Questions de synthèse.

1. Quelle décision consommera la sortie ?
2. Quelle erreur est la plus coûteuse ?
3. Un humain peut-il annoter le cas sans information supplémentaire ?

Complément 2 – Qualité d'un corpus

La taille ne corrige ni biais de sélection ni mauvaise annotation. Étudier sources, périodes, auteurs, doublons et données manquantes. Une partition aléatoire par phrase peut placer deux passages du même document dans train et test. Grouper selon l'unité susceptible de se répéter en production.

Questions de synthèse.

1. Quelle population le corpus représente-t-il ?
2. Quel regroupement empêche les fuites ?
3. Quelles transformations sont irréversibles ?

Complément 3 – Raisonnement linguistique

Une catégorie linguistique dépend du contexte. “Ferme” peut être nom, adjectif ou verbe ; “avocat” peut désigner une profession ou un fruit. Syntaxe et domaine réduisent l’ambiguïté. La pragmatique explique pourquoi “Pouvez-vous ouvrir la fenêtre ?” fonctionne comme demande plutôt que question de capacité.

Questions de synthèse.

1. Quels niveaux résolvent chaque ambiguïté ?
2. Quelle information manque à la phrase isolée ?
3. Comment représenter plusieurs interprétations possibles ?

Complément 4 – Pourquoi garder les baselines

Une régression logistique révèle rapidement si le signal lexical suffit. Ses poids aident à détecter fuite, artefact ou variable proxy. Si un Transformer gagne peu mais coûte beaucoup, la baseline peut être préférable. La comparaison doit employer mêmes partitions et métriques.

Questions de synthèse.

1. Quelle baseline naïve et quelle baseline forte choisir ?
2. Comment inspecter les variables dominantes ?
3. Quel gain justifie la complexité ?

Complément 5 – Décodage structuré

Prédire chaque label indépendamment peut produire 0 I-PER I-LOC. Un CRF attribue un score à la séquence et apprend les transitions plausibles. Les contraintes explicites peuvent interdire les transitions invalides. Elles améliorent la cohérence, sans corriger une taxonomie ambiguë.

Questions de synthèse.

1. Quelles transitions BIO sont impossibles ?
2. Quand une contrainte dure est-elle souhaitable ?
3. Pourquoi évaluer les segments complets ?

Complément 6 – Géométrie des embeddings

Un voisinage dépend du corpus, de l'objectif et de la métrique. La fréquence influence souvent norme et position. Une projection 2D déforme les distances et sert à explorer, pas à prouver des clusters. Les évaluations intrinsèques doivent être complétées par une tâche réelle.

Questions de synthèse.

1. Le vecteur représente-t-il type, occurrence ou document ?
2. Les vecteurs sont-ils normalisés ?
3. Quel test extrinsèque valide leur utilité ?

Complément 7 – Mémoire et séquences

Un RNN compresse tout le passé dans un état de taille fixe. LSTM crée un chemin additif contrôlé, mais n'élimine ni oubli ni coût séquentiel. Pour des documents longs, segmentation, attention ou mémoire externe peuvent être plus adaptées.

Questions de synthèse.

1. Où circule le gradient ?
2. Quel effet produit le clipping ?
3. Pourquoi l'inférence seq2seq accumule-t-elle les erreurs ?

Complément 8 – Interpréter l’attention

Les poids d’attention indiquent une pondération interne pour une tête et une couche données. Ils ne constituent pas automatiquement une explication fidèle de la décision finale, qui dépend aussi des résidus et MLP. Une analyse robuste compare interventions, gradients et contre-factuels.

Questions de synthèse.

1. Que somme le softmax ?
2. Pourquoi diviser par $\sqrt{d_k}$?
3. Quelle expérience testerait l’importance causale d’un token ?

Complément 9 – Seuils et abstention

Le seuil 0,5 n'est pas universel. Il dépend calibration, prévalence, coûts et capacité de revue. Une zone d'abstention peut transmettre les cas ambigus à un humain. Mesurer couverture et risque pour plusieurs seuils rend le compromis explicite.

Questions de synthèse.

1. Sur quel jeu choisir le seuil ?
2. Comment valoriser une abstention correcte ?
3. La prévalence changera-t-elle en production ?

Complément 10 – Propagation des erreurs

Dans un pipeline NER puis relations, une entité manquée rend sa relation impossible. Évaluer chaque étage avec entrées réelles et entrées oracle sépare ses erreurs propres de celles héritées. Une approche jointe peut aider, mais complique annotation et diagnostic.

Questions de synthèse.

1. Quel est le plafond imposé par l'étage précédent ?
2. Quelle évaluation oracle réaliser ?
3. Faut-il optimiser localement ou de bout en bout ?

Complément 11 – Plusieurs bonnes sorties

Traduction et résumé acceptent de nombreuses formulations. Une référence unique sous-estime cette diversité. Combiner métriques automatiques, contrôles factuels et préférence humaine. La grille doit distinguer erreurs de sens, omissions et style afin de guider l'amélioration.

Questions de synthèse.

1. Quelle propriété chaque métrique ignore-t-elle ?
2. Quelles erreurs peuvent être contrôlées automatiquement ?
3. Comment rendre l'annotation humaine reproductible ?

Complément 12 – Pertinence et utilisateur

Un document pertinent pour un annotateur peut être inaccessible, obsolète ou trop complexe pour l'utilisateur. L'évaluation en ligne observe clics et réussite mais subit biais de position. Les expériences randomisées et jugements hors ligne se complètent.

Questions de synthèse.

1. Quels niveaux de pertinence définir ?
2. Comment traiter les jugements manquants ?
3. Quelle métrique reflète l'ordre des premiers résultats ?

Complément 13 – Robustesse et équité

Tester fautes, paraphrases, longueurs et domaines révèle la sensibilité. Les groupes doivent être définis avec justification, droits et tailles suffisantes. Une différence n'indique pas automatiquement sa cause ; elle déclenche analyse des données, labels et usages.

Questions de synthèse.

1. Quels changements devraient préserver la prédiction ?
2. Quels intervalles entourent les écarts ?
3. Une mitigation dégrade-t-elle un autre groupe ?

Complément 14 – Exploiter durablement

Un modèle n'est qu'une version d'un système vivant. Conserver traçabilité de chaque prédiction, surveiller les entrées, attendre des labels fiables et préparer rollback. Les incidents deviennent des tests de non-régression. La responsabilité et la voie d'escalade doivent être connues avant la mise en service.

Questions de synthèse.

1. Quels SLO définir ?
2. Qui peut arrêter le système ?
3. Quelles données sont nécessaires sans violer la confidentialité ?

Chapitre 23

Glossaire et bibliographie

23.1 Glossaire

Corpus Collection documentée de textes.

Token Unité discrète traitée par un modèle.

Lemme Forme canonique de formes fléchies.

Morphème Unité minimale porteuse de fonction ou sens.

POS Catégorie morphosyntaxique contextualisée.

Embedding Représentation vectorielle dense.

CRF Modèle conditionnel de séquences.

Attention Agrégation pondérée de représentations.

Coréférence Relation entre mentions d'une même entité.

Calibration Accord entre confiance et fréquence de réussite.

Dérive Changement des données ou de la relation entrée–sortie.

23.2 Bibliographie commentée

Bibliographie

- [1] D. Jurafsky et J. Martin, *Speech and Language Processing*. Référence encyclopédique.
- [2] C. Manning et H. Schütze, *Foundations of Statistical NLP*. Fondements statistiques.
- [3] J. Eisenstein, *Introduction to Natural Language Processing*. Présentation moderne.
- [4] Y. Goldberg, *Neural Network Methods for NLP*. Méthodes neuronales.
- [5] T. Mikolov et al., *Efficient Estimation of Word Representations*, 2013.
- [6] A. Vaswani et al., *Attention Is All You Need*, 2017.
- [7] J. Devlin et al., *BERT*, 2018.

Conclusion

Le NLP relie structure du langage, données, modèles et décisions. La compétence durable consiste à formuler correctement la tâche, construire une évaluation crédible et analyser les erreurs avant d'ajouter de la complexité.